INFORME TÉCNICO · ANONIMIZADOR DE EXPEDIENTES XURÍDICOS

Características técnicas, robustez e seguridade do sistema

Detalle da implementación real do sistema de pseudonimización: como detecta os datos, como se protexe a información en repouso, e que garantías de robustez incorpora despois de probarse contra documentos reais dun despacho de avogados e contra boletíns oficiais.

VERSIÓN DO SOFTWARE	MARCO	IDIOMAS DA INTERFACE
Outubro de 2026	**RGPD (UE) 2016/679 · LOPDGDD**	**Castelán e galego**

01 · RESUMO

Que é e que garante

O sistema le documentos xurídicos (`.txt`, `.docx`, `.odt`, `.pdf`, incluídos escaneados, imaxes e arquivos `.zip`) e substitúe cada persoa física mencionada por un código opaco e estable (`PERSOA_000042`), xunto cos seus identificadores directos (DNI, teléfono, email, enderezo, matrícula…). Todo o procesamento é local: en ningún momento se envía texto a un servizo externo.

750+	15+	0
TESTS AUTOMATIZADOS	TIPOS DE IDENTIFICADOR DETECTADOS	CHAMADAS DE REDE DURANTE O USO

02 · ARQUITECTURA

O pipeline segue catro pasos, sempre na mesma orde, para calquera formato de entrada:

PASO	MÓDULO	FUNCIÓN
1. Inxesta	`pipeline.py`, `pdf.py`	Le o documento conservando a estrutura orixinal (parágrafos, táboas, runs de formato); en PDF, extrae texto nativo páxina a páxina e recorre a OCR só nas páxinas sen texto extraíble.
2. Detección	`ner.py`, `recognizers.py`	Combina un modelo de linguaxe (spaCy) para persoas/lugares cun conxunto de expresións regulares propias para identificadores administrativos españois.
3. Resolución de identidade	`resolution.py`, `registry.py`	Decide se cada mención corresponde a unha persoa xa coñecida (por DNI) ou a unha nova; nunca fusiona por só coincidir o nome.
4. Substitución e informe	`pipeline.py`, `risco_residual.py`	Substitúe no texto (ou no documento estruturado, conservando formato) e xera un informe para a revisión humana, incluíndo riscos de efecto mosaico e unha rede de seguridade final que avisa de posibles fugas sen detectar.

03 · QUE DETECTA

Persoas físicas (modelo de linguaxe + heurísticas propias)

Motor spaCy (`es_core_news_md`) ampliado con correccións atopadas ao probar contra documentos reais:

- **Texto en MAIÚSCULAS** (notas de poder, notas rexistrais, sinaturas oficiais): o modelo base practicamente non recoñecía persoas aquí — corrixido cunha transformación a «Title Case» só para a detección, sen alterar as posicións de caracteres do texto orixinal.
- **Apelidos compostos con conector** («del Rio», «de Cominges»): estendidos cara adiante cando o patrón é conector coñecido + palabra en maiúscula inicial.
- **Recorte de palabras absorbidas:** verbos ou profesións que o modelo incluía por erro despois do nome recórtanse comparando contra unha listaxe de palabras funcionais e profesións habituais en sinaturas.
- **Nomes «Apelidos, Nome»** (formato estándar en listaxes oficiais): o modelo de linguaxe recoñecía de forma inconsistente só unha das dúas metades. Corrixido cun recoñecedor por patrón determinista, independente do modelo estatístico.

Identificadores directos (expresións regulares propias)

DNI / NIE	Pasaporte	Teléfono
Email	Enderezo	Matrícula (actual e anterior a 2000)
IBAN	Tarxeta bancaria	Número da Seguridade Social
Referencia catastral	Número de colexiado/a	CSV
Número de referencia	Número de expediente	N.R.P. (Número de Rexistro de Persoal)

O DNI/NIE valídase sempre recalculando o díxito de control a partir dos números — nunca se confía na letra final tal como a le o OCR, unha fonte habitual de erro en dixitalizacións.

O **N.R.P.** leva o DNI incrustado nos seus primeiros 8 díxitos; nas listaxes oficiais a columna «D.N.I.» amosa eses díxitos soltos, sen letra de control. Recoñécese primeiro o N.R.P. e dedúcese del o DNI — nunca se redacta «calquera número de 8 díxitos», só os xa confirmados por un N.R.P. real. O patrón de **enderezo** nunca cruza un salto de liña (en táboas moi compactas fusionaba por erro un nome de pía coa cifra dunha liña adxacente).

CORRECCIÓN CRÍTICA ATOPADA DURANTE AS PROBAS

Un CSV (Código Seguro de Verificación) permite recuperar o documento ORIXINAL completo no portal do organismo emisor; un «número de referencia» de trámites xudiciais funciona igual. Deixalos sen redactar anulaba toda a anonimización aínda que se borrasen nomes e DNI. Atopado nun PDF real do despacho e corrixido de inmediato.

Nestes tres últimos casos (colexiado, CSV, referencia) só se redacta a cifra — a etiqueta que a acompaña («colegiado número», «Código Seguro de Verificación») queda visible, por petición expresa, para non perder contexto lexible no documento final.

Rede de seguridade final: escaneo de risco residual

Unha capa independente da detección primaria (módulo `risco_residual.py`): despois de anonimizar, volve escanear o texto *xa anonimizado* buscando patróns que aínda parezan datos persoais — nomes en formato «Apelidos, Nome» sen redactar, ou números soltos de 7 a 9 díxitos. Non redacta nada por si mesma: avisa para revisión humana, en dous niveis de confianza (alta / baixa, para separar avisos case seguros de revisión opcional). Amósase na interface de revisión, no resumo do modo automático e na saída da liña de comandos. Foi engadida despois de probar o sistema contra unha listaxe oficial real (BOE núm. 238, 2/outubro/2008: nomeamento de ~1.118 funcionarios de carreira), que tamén permitiu corrixir as tres categorías de fuga descritas arriba (nomes en orde inversa, N.R.P. e enderezos entre liñas), xa cubertas por probas automáticas.

04 · ROBUSTEZ

SITUACIÓN	COMPORTAMENTO
Documento moi longo (probado con 351 páxinas / 1,3M caracteres)	spaCy rexeita textos de máis de 1M de caracteres. O texto trocéase en anacos moi por debaixo dese límite, cortando sempre por saltos de liña para non partir unha mención pola metade.
PDF escaneado sen texto extraíble	Recorre automaticamente a OCR (Tesseract, `spa+glg`) só nas páxinas que o precisan; preprocesado con escala de grises e autocontraste.
Homónimos exactos (mesmo nome, persoas distintas)	Sen DNI que o confirme, NUNCA se fusionan automaticamente — créase un código novo marcado para revisión humana. Regra de deseño deliberadamente conservadora.
Documento .docx/.odt con formatos mesturados nun parágrafo	Consérvase o formato de cada «run»/«span» por separado; o documento final xérase sempre dende o orixinal máis as decisións da revisión.
Arquivo .zip con ficheiros non analizables (planos CAD, imaxes…)	Nunca se inclúen no .zip de saída — quedan listados explicitamente coma «omitidos» para que quede constancia do que non se puido revisar.
Servidor de revisión reiniciado a media revisión	As sesións pendentes sobreviven ao reinicio (gardadas cifradas); o documento orixinal nunca se persiste sen cifrar, recárgase sempre do ficheiro de orixe.
Cartafol enteiro con ficheiros de formatos mesturados (soportados e non)	Cada ficheiro soportado recibe a súa propia sesión de revisión; os non soportados quedan fóra e listados coma «omitidos», nunca se inclúen nin se modifican.
Un ficheiro dun lote falla (por exemplo, un PDF estragado)	O lote non se detén: o traballo segue co resto e os fallos lístanse ao final co seu motivo. A interface amosa o progreso en directo e permite cancelar o lote (remata o ficheiro en curso e non empeza o seguinte; o feito queda feito).

Cifrado en repouso

Todo o que contén identidades reais gárdase cifrado con Fernet (AES simétrico autenticado): o rexistro de correspondencias código↔persoa, o rexistro de auditoría, e as sesións de revisión pendentes. Nunca se escribe en disco ningún destes datos en claro.

Xestión da clave de cifrado

Dúas opcións, seleccionables por liña de comandos:

MODO	ONDE VIVE A CLAVE	CANDO USALO
Ficheiro local (por defecto)	`clave.key`, con permisos restrinxidos ao propietario	Probas, ou cando non hai chaveiro de sistema dispoñible.
`--chaveiro-sistema`	Administrador de credenciais de Windows (libraría `keyring`)	Recomendado para uso real — a clave non convive co que cifra. Os accesos e scripts de arranque do programa instalado xa o activan.

> **PUNTO CRÍTICO**
>
> Quen acceda ao rexistro de correspondencias reverte toda a anonimización de golpe. Por iso recibe o mesmo nivel de protección que os documentos orixinais, e a reversión require sempre un motivo explícito que queda na auditoría.

Reversión controlada, listado completo e auditoría

A reversión (recuperar a identidade real a partir dun código) e o listado completo (ver TODAS as correspondencias dun rexistro dunha vez) son as dúas únicas funcións de todo o sistema que devolven datos identificativos.

- Esixen sempre un **motivo** — non é opcional — e queda rexistrado cifrado xunto con quen o solicitou e cando.
- Esixen ademais un **contrasinal de reversión**, definido unha vez por rexistro: unha segunda barreira, á parte da clave de cifrado, que evita que outra persoa que comparta o ordenador reverta identidades sen coñecelo. Non é unha capa de cifrado adicional: quen teña á vez a clave e o rexistro cifrado pode descifralo igualmente. Os intentos fallidos quedan rexistrados na auditoría.
- Se nun rexistro antigo un código se fusionou noutro (versións anteriores do programa), a reversión segue o alias ata o código vixente; o listado completo amosa os códigos fusionados coma columna do código vixente, así que ningún desaparece.
- O listado completo é MÁIS sensible cá reversión (expón de golpe o rexistro enteiro, non un código coñecido de antemán): esixe ademais unha confirmación explícita, paxínase de 200 en 200 (cada páxina volve pedir o contrasinal), e queda auditado cunha acción propia (`listado_completo` / `listado_completo_denegado`) que a auditoría distingue sempre dunha reversión individual (`reversion`). Pódese gardar coma PDF CONFIDENCIAL, con marca de auga, pedindo de novo o contrasinal e unha confirmación expresa de que é un documento de extrema sensibilidade.
- O rexistro de auditoría rexistra tamén cada creación de código, cada posible homónimo e cada persoa desmarcada na revisión — nunca se pode editar nin borrar unha entrada individual.

Redacción real en PDF (non só visual)

Ao conservar o formato PDF orixinal, cada dato detectado elimínase do documento mediante redacción (`add_redact_annot` + `apply_redactions`), que reescribe o propio contido do ficheiro — non se limita a debuxar un recadro branco enriba. Isto aplícase por igual a texto vectorial e a píxeles de imaxe nunha páxina escaneada.

POR QUE IMPORTA ESTA DISTINCIÓN

Un PDF «redactado» só visualmente (un recadro branco ou negro enriba do texto) segue a conter o dato orixinal por debaixo — recuperable copiando o texto ou quitando a capa. A verificación deste sistema inclúe volver facer OCR sobre a imaxe FINAL dunha páxina escaneada xa redactada, para confirmar que o dato non é recuperable nin dos propios píxeles.

Funcionamento local

Non hai ningunha chamada de rede durante o procesamento dun documento, **nin sequera para instalar o programa**: Python, Tesseract, as librarías e o modelo de linguaxe van dentro do paquete de instalación, de xeito que o instalador funciona sen conexión a internet. A interface (unha xanela de escritorio propia) fala cun servidor interno que só escoita en `127.0.0.1`, nunca na rede.

Ese servidor local tamén está protexido fronte a outras páxinas abertas no MESMO navegador: calquera petición que cambie algo (gardar un contrasinal, confirmar unha revisión...) esixe que a orixe coincida coa propia app, e recházase calquera petición cun nome de host distinto de `127.0.0.1` / `localhost` — así unha web maliciosa noutra pestana, ou un dominio público que resolvese temporalmente ao propio equipo, non poden actuar sobre el.

06 · NOME DE FICHEIRO ANONIMIZADO

O nome do propio FICHEIRO tamén se revisa, non só o contido: é habitual gardar un documento coma «Certificado poder Jose Luis Lopez Rabadan.pdf» ou «DNI_30014811Z_escaneado.pdf» — deixar ese nome tal cal filtraría a identidade real aínda que o contido do documento quedase perfectamente anonimizado.

Como funciona

- Detéctanse persoas e DNI/NIE no propio nome de ficheiro coa mesma técnica có contido (modelo de linguaxe + expresións regulares), tanto en ficheiros soltos coma en cada entrada dun `.zip`.
- Usa o MESMO rexistro có contido do documento: se a persoa xa ten código (por DNI, ou por xa aparecer no propio documento), o nome de ficheiro reutiliza ese código — nunca crea unha identidade paralela para a mesma persoa.
- «_» e «-» (os separadores máis habituais en nomes de ficheiro, coma «Jose_Luis_Lopez_Rabadan») recoñécense igual cun espazo; o resto do nome mantense tal cal.
- Sen DNI que o confirme, un nome coincidente noutro ficheiro NUNCA se fusiona só — crea un código novo marcado, mesma regra conservadora có contido (sección 03).

CORRECCIÓN ATOPADA REVISANDO EXPEDIENTES REAIS

Varios documentos dun caso real levaban o nome da persoa directamente no nome do propio ficheiro (certificados de poder, títulos de propiedade…): o contido quedaba ben anonimizado, pero o nome do ficheiro deixaba a identidade real á vista. Corrixido para que o nome de saída use sempre o código de persoa, nunca o dato real.

07 · COBERTURA DE PROBAS

CATEGORÍA	QUE COBREN
Detección de persoas (NER)	Límites de entidade, texto en maiúsculas, apelidos con conector, documentos moi longos, nomes «Apelidos, Nome».
Identificadores directos	DNI/NIE (con corrección OCR), N.R.P., matrículas, enderezos, colexiado, CSV, referencia, IBAN, tarxeta, Seguridade Social, referencia catastral.

CATEGORÍA	QUE COBREN
Consistencia e resolución de identidade	Mesmo DNI → mesmo código; homónimos sen DNI → códigos distintos marcados.
Conservación de formato	.docx/.odt con táboas e mestura de estilos por parágrafo; PDF nativo e escaneado con redacción real (texto e píxeles de imaxe); imaxes soltas (.jpg, .png, .tif…) por OCR, gardadas no seu formato e sen metadatos.
Interface de revisión	Fluxo completo procesar → revisar → confirmar; persistencia de sesións; explorador de cartafoles propio e selector nativo de ficheiro; cartafol de saída; anonimización dun cartafol enteiro; progreso, fallos illados e cancelación de lotes; castelán e galego.
Reversión controlada e listado completo	Motivo obrigatorio, contrasinal de reversión, rexistro na auditoría (tamén dos intentos fallidos, con accións distintas para cada función), seguimento de alias, orde e paxinación do listado, confirmación explícita, e que un fallo de contrasinal non filtra ningún nome.
Chaveiro do sistema	Gardado/recuperación de clave, fallo con reserva a ficheiro, erro claro se a clave non se atopa.
ZIP e documentos grandes	Ficheiros soportados/omitidos, consistencia de códigos entre ficheiros dun mesmo zip, formato e extensión orixinais conservados en tódolos catro tipos.
Rede de seguridade final	Avisos de risco residual (nomes «Apelidos, Nome» e números soltos), en dous niveis de confianza.

08 · LIMITACIÓNS COÑECIDAS

- **Efecto mosaico:** detéctase por heurística configurable (profesión + lugar + data/idade próximos), non elimina o risco por completo — segue a facer falta revisión humana en casos de alto risco.
- **NER en galego:** usa o modelo de castelán por non haber aínda un modelo maduro de spaCy en galego; formas moi específicas do galego poden escapar á detección.
- Enderezos sen número preto do nome da vía (habitual en formularios con campos separados) non se detectan coma identificador directo.
- Resolución de identidade é intencionadamente conservadora: alcumes, iniciais ou grandes variacións ortográficas entre documentos distintos requiren revisión humana.
- **Redacción en PDF:** traballa a nivel de palabra enteira, non de carácter; o tamaño de letra do código inserido axústase automaticamente pero non replica o tipo de letra orixinal exacto. Columnas múltiples ou táboas complexas en PDF poden alterar a orde de lectura do texto reconstruído.

09 · CONCLUSIÓN

O sistema cobre de forma sólida e probada os requisitos funcionais e de seguridade centrais: detección exhaustiva, consistencia global, unicidade estrita, conservación de formato, reversión controlada, trazabilidade e funcionamento 100 % local. As limitacións que quedan son as propias de calquera sistema deste tipo (efecto mosaico, falsos negativos residuais) e están documentadas para que a revisión humana as poida cubrir.