INFORME TÉCNICO · ANONIMIZADOR DE EXPEDIENTES XURÍDICOS

Características técnicas, robustez e seguridade do sistema

Detalle da implementación real do sistema de pseudonimización: como detecta os datos, como se protexe a información en repouso, e que garantías de robustez incorpora despois de probarse contra documentos reais dun despacho de avogados e contra boletíns oficiais.

VERSIÓN DO SOFTWARE	MARCO	IDIOMAS DA INTERFACE
Outubro de 2026	**RGPD (UE) 2016/679 · LOPDGDD**	**Castelán e galego**

01 · RESUMO

Que é e que garante

O sistema le documentos xurídicos (`.txt` , `.docx` , `.odt` , `.pdf` , incluídos escaneados, imaxes e arquivos `.zip`) e substitúe cada persoa física mencionada por un código opaco e estable (`PERSOA_000042`), xunto cos seus identificadores directos (DNI, teléfono, email, enderezo, matrícula…). Todo o procesamento é local: en ningún momento se envía texto a un servizo externo.

750+	15+	0
TESTS AUTOMATIZADOS	TIPOS DE IDENTIFICADOR DETECTADOS	CHAMADAS DE REDE DURANTE O USO

02 · ARQUITECTURA

O pipeline segue catro pasos, sempre na mesma orde, para calquera formato de entrada:

PASO	MÓDULO	FUNCIÓN
1. Inxesta	`pipeline.py`, `pdf.py`	Le o documento conservando a estrutura orixinal (parágrafos, táboas, runs de formato); en PDF, extrae texto nativo páxina a páxina e recorre a OCR só nas páxinas sen texto extraíble.
2. Detección	`ner.py`, `recognizers.py`	Combina un modelo de linguaxe (spaCy) para persoas/lugares cun conxunto de expresións regulares propias para identificadores administrativos españois.
3. Resolución de identidade	`resolution.py`, `registry.py`	Decide se cada mención corresponde a unha persoa xa coñecida (por DNI) ou a unha nova; nunca fusiona por só coincidir o nome.
4. Substitución e informe	`pipeline.py`, `risco_residual.py`	Substitúe no texto (ou no documento estruturado, conservando formato) e xera un informe para a revisión humana, incluíndo riscos de efecto mosaico e unha rede de seguridade final que avisa de posibles fugas sen detectar.

03 · QUE DETECTA

Persoas físicas (modelo de linguaxe + heurísticas propias)

Motor spaCy (`es_core_news_md`) ampliado con correccións atopadas ao probar contra documentos reais:

- **Texto en MAIÚSCULAS** (notas de poder, notas rexistrais, sinaturas oficiais): o modelo base practicamente non recoñecía persoas aquí — corrixido cunha transformación a «Title Case» só para a detección, sen alterar as posicións de caracteres do texto orixinal.
- **Apelidos compostos con conector** («del Rio», «de Cominges»): estendidos cara adiante cando o patrón é conector coñecido + palabra en maiúscula inicial.
- **Recorte de palabras absorbidas:** verbos ou profesións que o modelo incluía por erro despois do nome recórtanse comparando contra unha listaxe de palabras funcionais e profesións habituais en sinaturas.
- **Nomes «Apelidos, Nome»** (formato estándar en listaxes oficiais): o modelo de linguaxe recoñecía de forma inconsistente só unha das dúas metades. Corrixido cun recoñecedor por patrón determinista, independente do modelo estatístico.

Identificadores directos (expresións regulares propias)

DNI / NIE	Pasaporte	Teléfono
Email	Enderezo	Matrícula (actual e anterior a 2000)
IBAN	Tarxeta bancaria	Número da Seguridade Social
Referencia catastral	Número de colexiado/a	CSV
Número de referencia	Número de expediente	N.R.P. (Número de Rexistro de Persoal)

O DNI/NIE valídase sempre recalculando o díxito de control a partir dos números — nunca se confía na letra final tal como a le o OCR, unha fonte habitual de erro en dixitalizacións.

O **N.R.P.** leva o DNI incrustado nos seus primeiros 8 díxitos; nas listaxes oficiais a columna «D.N.I.» amosa eses díxitos soltos, sen letra de control. Recoñécese primeiro o N.R.P. e dedúcese del o DNI — nunca se redacta «calquera número de 8 díxitos», só os xa confirmados por un N.R.P. real. O patrón de **enderezo** nunca cruza un salto de liña (en táboas moi compactas fusionaba por erro un nome de pía coa cifra dunha liña adxacente).

> **CORRECCIÓN CRÍTICA ATOPADA DURANTE AS PROBAS**
>
> Un CSV (Código Seguro de Verificación) permite recuperar o documento ORIXINAL completo no portal do organismo emisor; un «número de referencia» de trámites xudiciais funciona igual. Deixalos sen redactar anulaba toda a anonimización aínda que se borrasen nomes e DNI. Atopado nun PDF real do despacho e corrixido de inmediato.

Nestes tres últimos casos (colexiado, CSV, referencia) só se redacta a cifra — a etiqueta que a acompaña («colegiado número», «Código Seguro de Verificación») queda visible, por petición expresa, para non perder contexto lexible no documento final.

Rede de seguridade final: escaneo de risco residual

Unha capa independente da detección primaria (módulo `risco_residual.py`): despois de anonimizar, volve escanear o texto *xa anonimizado* buscando patróns que aínda parezan datos persoais — nomes en formato «Apelidos, Nome» sen redactar, ou números soltos de 7 a 9 díxitos. Non redacta nada por si mesma: avisa para revisión humana, en dous niveis de confianza (alta / baixa, para separar avisos case seguros de revisión opcional). Amósase na interface de revisión, no resumo do modo automático e na saída da liña de comandos. Foi engadida despois de probar o sistema contra unha listaxe oficial real (BOE núm. 238, 2/outubro/2008: nomeamento de ~1.118 funcionarios de carreira), que tamén permitiu corrixir as tres categorías de fuga descritas arriba (nomes en orde inversa, N.R.P. e enderezos entre liñas), xa cubertas por probas automáticas.

04 · ROBUSTEZ

SITUACIÓN	COMPORTAMENTO
Documento moi longo (probado con 351 páxinas / 1,3M caracteres)	spaCy rexeita textos de máis de 1M de caracteres. O texto trocéase en anacos moi por debaixo dese límite, cortando sempre por saltos de liña para non partir unha mención pola metade.
PDF escaneado sen texto extraíble	Recorre automaticamente a OCR (Tesseract, `spa+glg`) só nas páxinas que o precisan; preprocesado con escala de grises e autocontraste.
Homónimos exactos (mesmo nome, persoas distintas)	Sen DNI que o confirme, NUNCA se fusionan automaticamente — créase un código novo marcado para revisión humana. Regra de deseño deliberadamente conservadora.
Documento .docx/.odt con formatos mesturados nun parágrafo	Consérvase o formato de cada «run»/«span» por separado; o documento final xérase sempre dende o orixinal máis as decisións da revisión.
Arquivo .zip con ficheiros non analizables (planos CAD, imaxes…)	Nunca se inclúen no .zip de saída — quedan listados explicitamente coma «omitidos» para que quede constancia do que non se puido revisar.
Servidor de revisión reiniciado a media revisión	As sesións pendentes sobreviven ao reinicio (gardadas cifradas); o documento orixinal nunca se persiste sen cifrar, recárgase sempre do ficheiro de orixe.
Cartafol enteiro con ficheiros de formatos mesturados (soportados e non)	Cada ficheiro soportado recibe a súa propia sesión de revisión; os non soportados quedan fóra e listados coma «omitidos», nunca se inclúen nin se modifican.
Un ficheiro dun lote falla (por exemplo, un PDF estragado)	O lote non se detén: o traballo segue co resto e os fallos lístanse ao final co seu motivo. A interface amosa o progreso en directo e permite cancelar o lote (remata o ficheiro en curso e non empeza o seguinte; o feito queda feito).

Cifrado en repouso

Todo o que contén identidades reais gárdase cifrado con Fernet (AES simétrico autenticado): o rexistro de correspondencias código↔persoa, o rexistro de auditoría, e as sesións de revisión pendentes. Nunca se escribe en disco ningún destes datos en claro.

Xestión da clave de cifrado

Dúas opcións, seleccionables por liña de comandos:

MODO	ONDE VIVE A CLAVE	CANDO USALO
Ficheiro local (por defecto)	`clave.key`, con permisos restrinxidos ao propietario	Probas, ou cando non hai chaveiro de sistema dispoñible.
`--chaveiro-sistema`	Administrador de credenciais de Windows (libraría `keyring`)	Recomendado para uso real — a clave non convive co que cifra. Os accesos e scripts de arranque do programa instalado xa o activan.

> **PUNTO CRÍTICO**
> Quen acceda ao rexistro de correspondencias reverte toda a anonimización de golpe. Por iso recibe o mesmo nivel de protección que os documentos orixinais, e a reversión require sempre un motivo explícito que queda na auditoría.

Reversión controlada, listado completo e auditoría

A reversión (recuperar a identidade real a partir dun código) e o listado completo (ver TODAS as correspondencias dun rexistro dunha vez) son as dúas únicas funcións de todo o sistema que devolven datos identificativos.

- Esixen sempre un **motivo** — non é opcional — e queda rexistrado cifrado xunto con quen o solicitou e cando.
- Esixen ademais unha **contrasinal de reversión**, definida unha vez por rexistro: unha segunda barreira, á parte da clave de cifrado, que evita que outra persoa que comparta o ordenador reverta identidades sen coñecela. Non é unha capa de cifrado adicional: quen teña á vez a clave e o rexistro cifrado pode descifralo igualmente. Os intentos fallidos quedan rexistrados na auditoría.
- Se un código foi fusionado noutro tras unha revisión de homónimos, a reversión segue o alias ata o código vixente; o listado completo amosa os códigos fusionados coma columna do código vixente, así que ningún desaparece.
- O listado completo é MÁIS sensible cá reversión (expón de golpe o rexistro enteiro, non un código coñecido de antemán): esixe ademais unha confirmación explícita, paxínase de 200 en 200 (cada páxina volve pedir a contrasinal), e queda auditado cunha acción propia (`listado_completo` / `listado_completo_denegado`) que a auditoría distingue sempre dunha reversión individual (`reversion`). Pódese gardar coma PDF CONFIDENCIAL, con marca de auga, pedindo de novo a contrasinal e unha confirmación expresa de que é un documento de extrema sensibilidade.
- O rexistro de auditoría rexistra tamén cada creación de código, cada fusión e cada decisión de manter persoas separadas — nunca se pode editar nin borrar unha entrada individual.

Redacción real en PDF (non só visual)

Ao conservar o formato PDF orixinal, cada dato detectado elimínase do documento mediante redacción (`add_redact_annot + apply_redactions`), que reescribe o propio contido do ficheiro — non se limita a debuxar un recadro branco enriba. Isto aplícase por igual a texto vectorial e a píxeles de imaxe nunha páxina escaneada.

POR QUE IMPORTA ESTA DISTINCIÓN

Un PDF «redactado» só visualmente (un recadro branco ou negro enriba do texto) segue a conter o dato orixinal por debaixo — recuperable copiando o texto ou quitando a capa. A verificación deste sistema inclúe volver facer OCR sobre a imaxe FINAL dunha páxina escaneada xa redactada, para confirmar que o dato non é recuperable nin dos propios píxeles.

Funcionamento local

Non hai ningunha chamada de rede durante o procesamento dun documento, **nin sequera para instalar o programa**: Python, Tesseract, as librarías e o modelo de linguaxe van dentro do paquete de instalación, de xeito que o instalador funciona sen conexión a internet. A interface (unha xanela de escritorio propia) fala cun servidor interno que só escoita en `127.0.0.1`, nunca na rede.

Ese servidor local tamén está protexido fronte a outras páxinas abertas no MESMO navegador: calquera petición que cambie algo (gardar unha contrasinal, confirmar unha revisión...) esixe que a orixe coincida coa propia app, e recházase calquera petición cun nome de host distinto de `127.0.0.1` / `localhost` — así unha web maliciosa noutra pestana, ou un dominio público que resolvese temporalmente ao propio equipo, non poden actuar sobre el.

06 · NOME DE FICHEIRO ANONIMIZADO

O nome do propio FICHEIRO tamén se revisa, non só o contido: é habitual gardar un documento coma «Certificado poder Jose Luis Lopez Rabadan.pdf» ou «DNI_30014811Z_escaneado.pdf» — deixar ese nome tal cal filtraría a identidade real aínda que o contido do documento quedase perfectamente anonimizado.

Como funciona

- Detéctanse persoas e DNI/NIE no propio nome de ficheiro coa mesma técnica có contido (modelo de linguaxe + expresións regulares), tanto en ficheiros soltos coma en cada entrada dun `.zip`.
- Usa o MESMO rexistro có contido do documento: se a persoa xa ten código (por DNI, ou por xa aparecer no propio documento), o nome de ficheiro reutiliza ese código — nunca crea unha identidade paralela para a mesma persoa.
- «_» e «-» (os separadores máis habituais en nomes de ficheiro, coma «Jose_Luis_Lopez_Rabadan») recoñécense igual cun espazo; o resto do nome mantense tal cal.
- Sen DNI que o confirme, un nome coincidente noutro ficheiro NUNCA se fusiona só — crea un código novo marcado, mesma regra conservadora có contido (sección 03).

CORRECCIÓN ATOPADA REVISANDO EXPEDIENTES REAIS

Varios documentos dun caso real levaban o nome da persoa directamente no nome do propio ficheiro (certificados de poder, títulos de propiedade…): o contido quedaba ben anonimizado, pero o nome do ficheiro deixaba a identidade real á vista. Corrixido para que o nome de saída use sempre o código de persoa, nunca o dato real.

07 · COBERTURA DE PROBAS

CATEGORÍA	QUE COBREN
Detección de persoas (NER)	Límites de entidade, texto en maiúsculas, apelidos con conector, documentos moi longos, nomes «Apelidos, Nome».
Identificadores directos	DNI/NIE (con corrección OCR), N.R.P., matrículas, enderezos, colexiado, CSV, referencia, IBAN, tarxeta, Seguridade Social, referencia catastral.

CATEGORÍA	QUE COBREN
Consistencia e resolución de identidade	Mesmo DNI → mesmo código; homónimos sen DNI → códigos distintos marcados.
Conservación de formato	.docx/.odt con táboas e mestura de estilos por parágrafo; PDF nativo e escaneado con redacción real (texto e píxeles de imaxe).
Interface de revisión	Fluxo completo procesar → revisar → confirmar/fusionar; persistencia de sesións; explorador de cartafoles propio e selector nativo de ficheiro; cartafol de saída; anonimización dun cartafol enteiro; progreso, fallos illados e cancelación de lotes; castelán e galego.
Reversión controlada e listado completo	Motivo obrigatorio, contrasinal de reversión, rexistro na auditoría (tamén dos intentos fallidos, con accións distintas para cada función), seguimento de alias, orde e paxinación do listado, confirmación explícita, e que un fallo de contrasinal non filtra ningún nome.
Chaveiro do sistema	Gardado/recuperación de clave, fallo con reserva a ficheiro, erro claro se a clave non se atopa.
ZIP e documentos grandes	Ficheiros soportados/omitidos, consistencia de códigos entre ficheiros dun mesmo zip, formato e extensión orixinais conservados en tódolos catro tipos.
Rede de seguridade final	Avisos de risco residual (nomes «Apelidos, Nome» e números soltos), en dous niveis de confianza.

08 · LIMITACIÓNS COÑECIDAS

- **Efecto mosaico:** detéctase por heurística configurable (profesión + lugar + data/idade próximos), non elimina o risco por completo — segue a facer falta revisión humana en casos de alto risco.
- **NER en galego:** usa o modelo de castelán por non haber aínda un modelo maduro de spaCy en galego; formas moi específicas do galego poden escapar á detección.
- Enderezos sen número preto do nome da vía (habitual en formularios con campos separados) non se detectan coma identificador directo.
- Resolución de identidade é intencionadamente conservadora: alcumes, iniciais ou grandes variacións ortográficas entre documentos distintos requiren revisión humana.
- **Redacción en PDF:** traballa a nivel de palabra enteira, non de carácter; o tamaño de letra do código inserido axústase automaticamente pero non replica o tipo de letra orixinal exacto. Columnas múltiples ou táboas complexas en PDF poden alterar a orde de lectura do texto reconstruído.

09 · CONCLUSIÓN

O sistema cobre de forma sólida e probada os requisitos funcionais e de seguridade centrais: detección exhaustiva, consistencia global, unicidade estrita, conservación de formato, reversión controlada, trazabilidade e funcionamento 100 % local. As limitacións que quedan son as propias de calquera sistema deste tipo (efecto mosaico, falsos negativos residuais) e están documentadas para que a revisión humana as poida cubrir.