ESTATÍSTICA · ANONIMIZADOR DE EXPEDIENTES XURÍDICOS

Canto mellora e canto acerta a versión 20261011

Medición da versión instalada en Windows o 11 de outubro de 2026 fronte á anterior (20261004), e proba da súa fiabilidade con 500 documentos reais do BOE e do DOG de 2024 procesados pola instalación de Windows. Só cifras: ningún dato persoal dos documentos.

VERSIÓN MEDIDA	FRONTE A	DATA
20261011-9a30d66	**20261004-5a43ade**	**11 de outubro de 2026**

01 · EN POUCAS PALABRAS

A versión nova **tapa menos cousas que non son persoas** (lugares, organismos, encabezados, cargos) **sen destapar ningunha persoa** en ningunha das medicións. Na proba con 500 documentos que nunca se viran, a instalación de Windows deixou **sen ningún dato persoal á vista 56 de cada 60** documentos lidos; os fallos que quedan son sobre todo **nomes de pía parciais** (o apelido si se tapa).

0
en 780 documentos comparados
persoas que a versión nova destapa e a anterior tapaba

–28 %
102 → 73 nos lotes 3 e 4
trozos tapados nun sitio e á vista noutro (control automático)

98 %
IC 95 %: 96–99 %
persoas tapadas enteiras na mostra de 2024

497 / 499
Windows fronte a Mac
documentos co mesmo resultado nos dous sistemas

02 · QUE MELLORA FRONTE Á VERSIÓN ANTERIOR

As dúas versións procesaron os mesmos documentos e compáraronse os anacos tapados un a un. Cada diferenza leuse para saber se era unha persoa ou non.

MEDICIÓN	DOCUMENTOS	DESTAPADO	PERSOAS DESTAPADAS	TAPADO NOVO
Lotes 3 e 4 (BOE e DOG, xullo de 2025 a maio de 2026)	560	152 anacos	**0**	0
Lote 5, documentos non revisados (xaneiro-xuño de 2025)	220	3 anacos	**0**	0

O destapado son, entre outros, municipios e lugares que coinciden con apelidos, nomes de organismos e centros docentes, encabezados de formulario e de anexo en maiúsculas, siglas con puntos, nomes de plantas solares, especies en latín e a «Sala» dun tribunal. Indicador do control automático «tapado nun sitio e á vista noutro» (sinal de algo que non era persoa e se tapou):

LOTE	VERSIÓN 20261004	VERSIÓN 20261011*	MELLORA
Lote 3 (280 docs, xaneiro-maio de 2026)	43	**29**	–33 %
Lote 4 (280 docs, xullo-decembro de 2025)	59	**44**	–25 %

* Medido coa integración do 10 de outubro, que é a versión 20261011 sen os últimos arranxos do lote 5; con eles o resultado só pode ser igual ou mellor, porque no lote 5 non tapan nada novo.

Tamén se arranxou unha fuga: un apelido que coincide coa palabra dun organismo («Xulgado» coma apelido) quedaba á vista nun anexo de nomeamentos.

> **LOTE 5 REVISADO (60 DOCUMENTOS): CIFRA SÓ ORIENTATIVA**
>
> Nos 60 documentos que se revisaron a man, a parte do tapado que era de verdade unha persoa pasou do **73,2 % ao 90,1 %**, e os documentos perfectos do 68 % ao 75 %. Está sesgada a favor: os arranxos fixéronse mirando eses documentos. Por iso as cifras de arriba e as da sección 03 usan só documentos que ninguén mirara.

03 · FIABILIDADE: 500 DOCUMENTOS DE 2024 COA INSTALACIÓN DE WINDOWS

Descargáronse 500 documentos públicos de 2024 (360 do BOE e 140 do DOG), un ano que nunca se usara nas probas. Procesáronse coa versión instalada nunha máquina Windows 11, do mesmo xeito ca o modo automático do programa. Antes de procesar nada escolléronse ao chou 60 documentos (40 do BOE e 20 do DOG) e leronse enteiros comparando o orixinal co resultado.

MOSTRA DE 60 DOCUMENTOS LIDOS	RESULTADO	INTERVALO 95 %
Documentos sen ningún dato persoal á vista	**56 de 60 · 93,3 %**	84,1–97,4 %
Persoas tapadas enteiras	**405 de 413 · 98,1 %**	96,2–99,0 %
Documentos con algo tapado que non é persoa	21 de 60 · 35,0 %	24,2–47,6 %
Documentos cun DNI asignado ao código doutra persoa	3 de 60 · 5,0 %	1,7–13,7 %
Documentos perfectos (sen ningún dos anteriores)	**36 de 60 · 60,0 %**	47,4–71,4 %

As 8 persoas que non quedaron enteiras están en 4 documentos. En 7 queda á vista **só unha parte do nome** (o nome de pía, as iniciais ou un anaco de apelido cortado cun guión) e o resto tápase; son nomes compostos cataláns, «M.ª» pegado ao nome e iniciais tras o nome. Só nun caso queda un nome completo: estaba cortado cun guión ao final da liña.

Resto dos 500 documentos (control automático, sen lectura): atopou outros 4 documentos con nomes á vista: dous con nomes partidos entre dúas liñas (un deles cun guión), un cun nome estranxeiro e un no que o nome do título quedou á vista aínda que se tapou no resto do texto. O control automático só ve nomes que se taparon noutro sitio do mesmo documento, así que non substitúe a lectura da mostra.

Windows e Mac: a instalación de Windows procesou 499 dos 500 documentos (o que falta falla tamén en Mac, ver sección 04), en 2 h 32 min en total e unha mediana de 5 segundos por documento. O texto dos PDF que xera é idéntico ao do programa en Mac en 497 de 499; nos outros 2 só cambia como se le o logotipo da Xunta ao pé dunha páxina do DOG (o recoñecemento de texto da imaxe dá letras distintas en cada sistema), sen ningún dato persoal.

Texto conservado: o PDF de saída perdeu 59 palabras que non debía en 5 dos 499 documentos (37 delas nun só documento, arredor dun enderezo que se repite nunha táboa). No resto, o texto non persoal queda intacto.

04 · QUE QUEDA POR ARRANXAR

- **Nomes cortados ao final da liña**, con guión ou sen el, e nomes de pía abreviados ou unidos («M.ª» pegado ao nome, unha inicial solta diante): é o fallo máis repetido.
- **DNI dun anexo co código de quen asina**: cando un anuncio leva un anexo só con DNI, o primeiro pode recibir o código da persoa que asina enriba. Non deixa nada á vista, pero no documento parece que ese DNI é de quen asina.
- **Sobreanonimización**: aínda se tapan algúns cargos («Fiscal Delegado», «Rector Magnífico»), rótulos de formulario en maiúsculas, nomes de entidades e palabras soltas («Marco», «Test»).
- **Un PDF que non se pode procesar** (1 de 500): o programa avisa do erro e non xera saída. Falla igual en Windows e en Mac.

A REVISIÓN HUMANA SEGUE SENDO NECESARIA

Estes resultados son da lectura dunha mostra feita por Claude, sen revisión humana. Ningún sistema garante o 100 %: antes de entregar un documento anonimizado, revisa sobre todo as táboas, as listaxes de persoas e os nomes partidos entre liñas.

05 · COMO SE MEDIU

- Comparación de versións: o mesmo código da versión 20261004 e da nova sobre os mesmos documentos; lense todas as diferenzas.
- Proba de 2024: 500 documentos públicos descargados respectando as condicións de reutilización do BOE e do DOG, procesados na máquina virtual Windows 11 coa instalación real 20261011-9a30d66 e un rexistro de proba (o rexistro real non se tocou).
- Mostra: 60 documentos escollidos co número de semente 20261011 antes de procesar ningún. Intervalos de confianza de Wilson ao 95 %. Os documentos moi longos (3 de 60) revisáronse por todo o tapado e por patróns de nome, non palabra a palabra.
- Control automático: relectura de cada PDF de saída buscando nomes á vista, texto oculto e outros indicios; 500 de 500 documentos.
- As cifras son de documentos oficiais publicados; noutros tipos de escrito (demandas, contratos) poden ser distintas.